



Wrocław University
of Science and Technology

Regresja liniowa

Szymon Zaręba

`szymon.zareba@pwr.edu.pl`

Probabilistyczny model regresji liniowej

Model

Przyjmijmy następujący model:

$$y = \phi(x)^T \mathbf{w} + \varepsilon,$$

gdzie $\varepsilon \sim \mathcal{N}(\varepsilon|0, \sigma^2)$ oznacza zakłócenie.



Zauważmy, że

$$p(y|x, \mathbf{w}, \sigma^2) = \mathcal{N}(y|\phi(x)^T \mathbf{w}, \sigma^2),$$

ponieważ

$$\mathbb{E}[y] = \mathbb{E}[\phi(x)^T \mathbf{w} + \varepsilon] = \phi(x)^T \mathbf{w}$$

$$\text{Var}[y] = \text{Var}[\phi(x)^T \mathbf{w} + \varepsilon] = \sigma^2$$



Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć funkcję wiarygodności:

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć funkcję wiarygodności:

$$p(Y|X, \mathbf{w}, \sigma^2) = \prod_{n=1}^N p(y_n|x_n, \mathbf{w}, \sigma^2) = \prod_{n=1}^N \mathcal{N}(y_n|\boldsymbol{\phi}(x_n)^T \mathbf{w}, \sigma^2),$$

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć funkcję wiarygodności:

$$p(Y|X, \mathbf{w}, \sigma^2) = \prod_{n=1}^N p(y_n|x_n, \mathbf{w}, \sigma^2) = \prod_{n=1}^N \mathcal{N}(y_n|\boldsymbol{\phi}(x_n)^T \mathbf{w}, \sigma^2),$$

po wstawieniu rozkładu normalnego:

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć funkcję wiarygodności:

$$p(Y|X, \mathbf{w}, \sigma^2) = \prod_{n=1}^N p(y_n|x_n, \mathbf{w}, \sigma^2) = \prod_{n=1}^N \mathcal{N}(y_n|\boldsymbol{\phi}(x_n)^T \mathbf{w}, \sigma^2),$$

po wstawieniu rozkładu normalnego:

$$p(Y|X, \mathbf{w}, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp -\frac{(y_n - \boldsymbol{\phi}(x_n)^T \mathbf{w})^2}{2\sigma^2}$$

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć logarytm funkcji wiarygodności:

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć logarytm funkcji wiarygodności:

$$\ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \|Y - \Phi\mathbf{w}\|_2^2$$

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć logarytm funkcji wiarygodności:

$$\ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \|Y - \Phi \mathbf{w}\|_2^2$$

wyznaczyć jego gradient:

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć logarytm funkcji wiarygodności:

$$\ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \|Y - \Phi \mathbf{w}\|_2^2$$

wyznaczyć jego gradient:

$$\nabla_{\mathbf{w}} \ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} (-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w})$$

Probabilistyczny model regresji liniowej

Uczenie

Można wyznaczyć logarytm funkcji wiarygodności:

$$\ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \|Y - \Phi \mathbf{w}\|_2^2$$

wyznaczyć jego gradient:

$$\nabla_{\mathbf{w}} \ln p(Y|X, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} (-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w})$$

i rozwiązać względem \mathbf{w} :

$$-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w} = 0$$

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

Probabilistyczny model regresji liniowej

Predykcja

Teoria decyzji mówi, że optymalnym wyborem jest y , który minimalizuje ryzyko (średnią stratę) przy zadanej funkcji straty.

Mając:

- $p(y|x, \mathbf{w})$ - model
- $y \in \mathbb{R}$ - zbiór możliwych decyzji
- $L(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2$ - funkcja straty

$$R(\hat{y}) = \mathbb{E}[L(y, \hat{y})] = \int \frac{1}{2}(y - \hat{y})^2 p(y|x) dy$$

$$y^* = \underset{\hat{y}}{\operatorname{argmin}} R(\hat{y})$$

Probabilistyczny model regresji liniowej

Predykcja

Należy policzyć pochodną ryzyka względem podejmowanej decyzji:

Probabilistyczny model regresji liniowej

Predykcja

Należy policzyć pochodną ryzyka względem podejmowanej decyzji:

$$\frac{\partial R(\hat{y})}{\partial \hat{y}} = - \int (y - \hat{y}) p(y|x) dy$$

Probabilistyczny model regresji liniowej

Predykcja

Należy policzyć pochodną ryzyka względem podejmowanej decyzji:

$$\frac{\partial R(\hat{y})}{\partial \hat{y}} = - \int (y - \hat{y}) p(y|x) dy$$

i wyznaczyć optymalną wartość decyzji:

Probabilistyczny model regresji liniowej

Predykcja

Należy policzyć pochodną ryzyka względem podejmowanej decyzji:

$$\frac{\partial R(\hat{y})}{\partial \hat{y}} = - \int (y - \hat{y}) p(y|x) dy$$

i wyznaczyć optymalną wartość decyzji:

$$- \int (y - \hat{y}) p(y|x) dy = 0$$

$$\int y p(y|x) dy - \int \hat{y} p(y|x) dy = 0$$

$$\mathbb{E}[y] - \hat{y} \int p(y|x) dy = 0$$

$$\mathbb{E}[y] - \hat{y} = 0$$

$$\hat{y} = \mathbb{E}[y] = \boldsymbol{\phi}(x)^T \mathbf{w}$$

Probabilistyczny model regresji liniowej z apriori

Model

Przyjmijmy następujący model:

$$p(y|x, \mathbf{w}, \sigma^2) = \mathcal{N}(y|\phi(x)^T \mathbf{w}, \sigma^2).$$

Przyjmijmy następujący rozkład a priori na parametry \mathbf{w} :

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|0, \alpha^2 \mathbb{I}) = \frac{1}{(2\pi)^{M/2}} \frac{1}{|\alpha^2 \mathbb{I}|^{1/2}} \exp \left\{ -\frac{1}{2} \mathbf{w}^T (\alpha^2 \mathbb{I})^{-1} \mathbf{w} \right\},$$

gdzie

$$\det(\alpha^2 \mathbb{I}) = \alpha^{2M}$$

$$(\alpha^2 \mathbb{I})^{-1} = \frac{1}{\alpha^2} \mathbb{I}$$

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć rozkład a posteriori:

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć rozkład a posteriori:

$$p(\mathbf{w}|X, Y) = \frac{p(Y|X, \mathbf{w})p(\mathbf{w})}{p(Y|X)}$$

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć rozkład a posteriori:


$$p(\mathbf{w}|X, Y) = \frac{p(Y|X, \mathbf{w})p(\mathbf{w})}{p(Y|X)}$$

po wstawieniu odpowiednich rozkładów:

$$p(\mathbf{w}|X, Y) = \frac{\mathcal{N}(\mathbf{w}|0, \alpha^2 \mathbb{I}) \prod_{n=1}^N \mathcal{N}(y_n | \phi(x_n)^T \mathbf{w}, \sigma^2)}{p(Y|X)}$$

Probabilistyczny model regresji liniowej z apriori

Uczenie



Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć logarytm rozkładu a posteriori:

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć logarytm rozkładu a posteriori:

$$\begin{aligned}\ln p(\mathbf{w}|X, Y) &= \ln \left(\frac{1}{(2\pi)^{M/2}} \frac{1}{(\alpha^2)^{M/2}} \exp \left\{ -\frac{1}{2\alpha^2} \|\mathbf{w}\|_2^2 \right\} \right) \\ &\quad + \ln \left(\prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \phi(x_n)^T \mathbf{w})^2 \right\} \right) \\ &\quad - \ln p(Y|X) \\ &= -\frac{M}{2} \ln 2\pi - \frac{M}{2} \ln \alpha^2 - \frac{1}{2\alpha^2} \|\mathbf{w}\|_2^2 \\ &\quad - \frac{N}{2} \ln 2\pi - \frac{N}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \|Y - \Phi \mathbf{w}\|_2^2 \\ &\quad - \ln p(Y|X)\end{aligned}$$

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć gradient logarytmu rozkładu a posteriori względem parametrów w :

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć gradient logarytmu rozkładu a posteriori względem parametrów \mathbf{w} :

$$\nabla_{\mathbf{w}} \ln p(\mathbf{w}|X, Y) = -\frac{1}{2\sigma^2} 2\mathbf{w} - \frac{1}{2\sigma^2} (-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w})$$

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć gradient logarytmu rozkładu a posteriori względem parametrów \mathbf{w} :

$$\nabla_{\mathbf{w}} \ln p(\mathbf{w}|X, Y) = -\frac{1}{2\sigma^2} 2\mathbf{w} - \frac{1}{2\sigma^2} (-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w})$$

i wyznaczyć optymalną wartość \mathbf{w} :

Probabilistyczny model regresji liniowej z apriori

Uczenie

Można wyznaczyć gradient logarytmu rozkładu a posteriori względem parametrów \mathbf{w} :

$$\nabla_{\mathbf{w}} \ln p(\mathbf{w}|X, Y) = -\frac{1}{2\alpha^2}2\mathbf{w} - \frac{1}{2\sigma^2}(-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w})$$

i wyznaczyć optymalną wartość \mathbf{w} :

$$-\frac{1}{2\alpha^2}2\mathbf{w} - \frac{1}{2\sigma^2}(-2\Phi^T Y + 2\Phi^T \Phi \mathbf{w}) = 0$$

$$\Phi^T Y - \Phi^T \Phi \mathbf{w} - \frac{\sigma^2}{\alpha^2} \mathbf{w} = 0$$

$$\mathbf{w} = (\Phi^T \Phi + \frac{\sigma^2}{\alpha^2} \mathbb{I})^{-1} \Phi^T Y$$